

Technical Write-up Task 1

Prediksi Kecepatan Lalu Lintas Beijing

1. Konteks masalah

Task ini meminta prediksi kecepatan lalu lintas pada 1.260 ruas jalan di dalam Ring Road ke-5 Beijing untuk tiga horizon ke depan, yaitu 20 menit (h5), 40 menit (h10), dan 60 menit (h15). Satu langkah waktu setara dengan 4 menit. Tersedia tiga sumber sinyal, yaitu riwayat kecepatan 15 langkah terakhir untuk seluruh segmen, teks berbahasa Inggris yang mendeskripsikan kejadian di jaringan jalan pada langkah tersebut, serta adjacency matrix berarah berukuran 1260 kali 1260 beserta metadata tiap segmen.

Data latih terdiri dari dua blok waktu kontinu, yaitu m1 sepanjang 11.160 langkah dan m2 sepanjang 5.039 langkah. Data uji berisi 540 window sepanjang 15 langkah, sehingga file submission berisi 2.041.200 baris. Metrik penilaiannya MSE, sehingga kesalahan besar dihukum secara kuadratik dan penanganan kasus ekstrem lebih menentukan skor dibanding perbaikan rata-rata pada kasus normal.

2. Ringkasan pendekatan

Keputusan paling menentukan di solusi kami adalah memperlakukan masalah ini sebagai prediksi residual terhadap baseline persistence, bukan prediksi kecepatan mentah. Alasannya, tebakan naif berupa nilai terakhir sudah menjelaskan mayoritas varians, sehingga pekerjaan model yang sebenarnya adalah memprediksi perubahan dari kondisi sekarang. Target yang dipelajari model adalah selisih antara kecepatan pada horizon tertentu dengan kecepatan terakhir di window.

Di atas formulasi itu kami melatih LightGBM dengan satu model terpisah per horizon, memakai 45 fitur yang dibangun dari riwayat kecepatan, struktur graf jalan, metadata segmen, dan hasil pemetaan teks kejadian ke segmen. Empat varian model dilatih dengan konfigurasi berbeda, lalu digabung memakai bobot least squares yang dihitung di data holdout. Prediksi akhir adalah nilai terakhir ditambah residual gabungan, dipotong ke rentang yang wajar, dengan penanganan khusus untuk sensor mati.

3. Temuan eksplorasi yang menentukan desain

Ada empat temuan yang menjadi dasar hampir semua keputusan berikutnya.

- Nilai kecepatan 0 berarti sensor mati, bukan jalan macet total. Nol terkonsentrasi pada segmen tertentu dan sangat persisten, dengan 13 segmen mati di m1 dan 210 di m2. Salah menangani ini fatal untuk MSE, karena menebak 50 saat nilai sebenarnya 0 memberi penalti 2.500 pada satu baris saja.
- Persistence adalah baseline yang kuat, dengan MSE holdout 40,11 untuk h5, 44,25 untuk h10, dan 47,68 untuk h15. Rata-rata historis per segmen justru lebih buruk daripada persistence.
- Kecepatan bersifat mean reverting. Segmen yang baru saja anjlok cenderung memantul kembali ke level normalnya. Ini menjadi sumber perbaikan terbesar atas persistence, dan fitur selisih nilai terakhir terhadap rata-rata window menjadi fitur paling berpengaruh di model.
- Teks kejadian sangat repetitif antar langkah waktu. Penutupan jangka panjang muncul di ribuan langkah berturut-turut dan seluruh korpus hanya memuat sekitar 185 lokasi unik, sehingga informasi marginal per langkah kecil dan sebagian besar sudah terserap di level kecepatan saat ini.

4. Kerangka validasi

Karena label data uji tidak tersedia, satu-satunya kompas yang kami punya adalah holdout lokal yang jujur, sehingga bagian ini disiapkan lebih dulu sebelum modeling dimulai. Sebanyak 720 langkah terakhir dari tiap blok, setara dua hari, disisihkan sebagai zona validasi dan sisanya dipakai untuk training.

Satu window didefinisikan oleh indeks akhirnya. Untuk mencegah kebocoran waktu, window training terakhir dipaksa berjarak minimal 30 langkah dari window validasi pertama, sehingga tidak ada satu titik waktu pun yang dipakai bersama oleh fitur atau target di kedua sisi. Statistik per segmen seperti rata-rata historis juga dihitung hanya dari porsi training. Seluruh keputusan, mulai dari fitur mana yang dipakai, kapasitas model, bobot penggabungan, sampai pemilihan submission akhir, diambil hanya dari angka holdout ini.

5. Fitur

Satu baris data adalah kombinasi window dan segmen, sehingga satu model belajar lintas 1.260 segmen sekaligus. Dengan stride 2 antar window, jumlah baris training dari kedua blok mencapai sekitar 8,8 juta. Total ada 45 kolom fitur yang dikelompokkan sebagai berikut.

- Riwayat per segmen, berupa nilai terakhir, rata-rata dan simpangan baku 15 langkah, rata-rata 5 dan 3 langkah terakhir, selisih 1 dan 4 langkah, serta nilai minimum dan maksimum window.
- Mean reversion, berupa selisih nilai terakhir terhadap rata-rata window, rata-rata historis segmen yang dihitung dari porsi training saja, dan selisih nilai terakhir terhadap rata-rata historis tersebut. Kelompok ini yang paling berpengaruh.
- Indikator sensor mati, berupa fraksi nilai nol di window, penanda nilai terakhir sama dengan nol, dan penanda seluruh window bernilai nol.
- Agregat tetangga di graf berarah, yaitu rata-rata ternormalisasi kecepatan tetangga masuk dan tetangga keluar untuk jarak 1 hop dan 2 hop, mengikuti arah edge. Ini menangkap perambatan kemacetan lewat topologi jalan.
- Kondisi global jaringan, berupa rata-rata kecepatan segmen yang hidup dan perubahannya, yang berfungsi sebagai proksi kasar rezim lalu lintas.
- Metadata statis segmen, yaitu roadclass, formway, panjang, jumlah sub segmen, derajat masuk, derajat keluar, dan id segmen sebagai fitur kategorikal.
- Fitur teks, terdiri dari hitungan kata kunci di seluruh teks pada langkah tersebut, serta flag kejadian per segmen untuk enam kelas, yaitu closure, accident, construction, control, prohibit, dan other, ditambah spillover flag kecelakaan dari tetangga.

Flag kejadian per segmen membutuhkan pemetaan nama jalan, karena teks menyebut jalan dalam bahasa Inggris sementara metadata segmen memakai nama hanzi. Kosakatanya ternyata kecil, sekitar 191 nama hanzi dan 185 lokasi bahasa Inggris, sehingga masalahnya adalah pemetaan berhingga, bukan NLP terbuka. Tiap nama hanzi diubah menjadi sejumlah kandidat token lewat pinyin dan kamus arah, angka, serta akhiran jalan, lalu dicocokkan dengan skor overlap token berbobot ditambah bonus kesamaan urutan. Bonus urutan diperlukan untuk membedakan kasus seperti north third ring east road dan east third ring north road yang himpunan tokennya identik. Coverage akhir mencapai 99,5 persen dari seluruh penyebutan lokasi.

6. Model dan penggabungan

Kami melatih satu model LightGBM per horizon dengan objective regression dan metric L2 agar sejalan langsung dengan metrik lomba, dengan early stopping memakai holdout. Baris yang seluruh windownya nol berasal dari sensor mati dan jumlahnya besar, sehingga hanya 15 persen di antaranya diikutkan ke training supaya model tidak didominasi kasus itu.

Empat varian dilatih dengan perbedaan pada stride, subset fitur, dan kapasitas pohon. Varian v1 memakai stride 4 dan fitur tanpa agregat 2 hop dengan 96 leaves, v2 memakai stride 2 dan menambahkan fitur 2 hop, v3 menaikkan kapasitas ke 255 leaves dengan learning rate lebih kecil, dan v4 sama dengan v3 ditambah delapan fitur kejadian per segmen. Perbedaan konfigurasi ini dipilih supaya kesalahan antar model tidak seragam, sehingga penggabungan memberi manfaat.

Bobot penggabungan dihitung closed form per horizon dengan least squares di holdout, yaitu mencari bobot yang meminimalkan selisih antara kombinasi residual prediksi keempat model dengan residual sebenarnya. Hasilnya v3 dan v4 dominan, v1 kecil positif, dan v2 bernilai sedikit

negatif pada h10 dan h15. Bobot negatif seperti ini wajar muncul ketika model saling berkorelasi, karena perannya adalah koreksi terhadap model lain, bukan kontribusi mandiri.

7. Post-processing

Prediksi akhir dihitung sebagai nilai terakhir ditambah residual gabungan, lalu dipotong ke rentang 0 sampai 150 km per jam. Baris yang seluruh window testnya bernilai nol dipaksa menjadi 0, karena segmen mati hampir pasti tetap mati satu jam kemudian dan menebak angka positif di situ sangat mahal untuk MSE. Terakhir, urutan id pada file submission diverifikasi sama persis dengan sample submission memakai assert sebelum file ditulis.

8. Yang dicoba dan tidak dipakai

Kami sempat mencoba menebak waktu dalam hari untuk data uji, karena fitur ini biasanya kuat pada masalah lalu lintas. Identy mencocokkan kurva rata-rata jaringan sepanjang 15 langkah ke profil harian dari data train, lalu diuji dengan menganggap window holdout sebagai window yang tidak dikenal. Median kesalahannya 3 sampai 5 jam, karena kurva sepanjang satu jam terlalu ambigu dan level kecepatan yang mirip muncul di banyak jam berbeda. Fitur ini akhirnya tidak dipakai sama sekali, termasuk untuk training, supaya distribusi fitur train dan test tetap sama. Pelajarannya, fitur sekuat apa pun di data latih tidak berguna kalau tidak bisa dibangun di data uji.

Fitur kejadian per segmen berhasil secara teknik tetapi netral secara skor. Pemeriksaan sinyal menunjukkan baris yang berflag kecelakaan punya residual h15 sekitar 0,8 km per jam lebih tinggi dan MSE 35 persen lebih besar, jadi sinyalnya nyata. Namun varian v4 yang memakai fitur ini hasilnya praktis setara v3. Kesimpulan jujurinya, informasi kejadian sebagian besar sudah terkodekan oleh fitur mean reversion dari riwayat kecepatan itu sendiri. Fitur ini tetap dipertahankan karena menambah keragaman ensemble.

9. Hasil

Model	h5	h10	h15	Rata-rata
Persistence	40,11	44,25	47,68	44,02
Model tunggal terbaik (v3)	24,47	27,78	30,91	27,72
Gabungan 4 model (final)	24,43	27,72	30,81	27,65

Seluruh angka di tabel adalah MSE pada holdout lokal. Gabungan empat model unggul atas semua model tunggal di ketiga horizon, dengan perbaikan sekitar 37 persen dibanding baseline persistence.

Skor leaderboard untuk submission ini adalah 40,161, lebih tinggi daripada rata-rata holdout kami yang 27,65. Selisih itu menunjukkan periode data uji punya karakteristik berbeda dari dua hari terakhir tiap blok yang kami pakai sebagai holdout, dan tanpa label data uji kami tidak bisa memverifikasi penyebab pastinya. Holdout tetap dipakai sebagai dasar seluruh keputusan karena itu satu-satunya sinyal yang tersedia, dan urutan perbandingan antar model di holdout konsisten di ketiga horizon.

10. Waktu eksekusi dan dependensi

Seluruh pipeline berjalan di CPU dengan 16 thread, puncak RAM sekitar 3 GB, dan total runtime dari nol sampai file submission sekitar 30 sampai 40 menit dengan porsi terbesar pada training. Dependensi di luar bawaan Anaconda hanya lightgbm dan pypinyin. Seed difiksasi pada 42, sehingga hasilnya deterministik kecuali variasi kecil akibat threading LightGBM. Notebook membangun ulang seluruh hasil ini dari nol.